

Analitik Transportasi dan Mobilitas Perkotaan New York City Berbasis Integrasi Data 311 dan Cuaca: Implementasi dan Perbandingan Pipeline ETL dan ELT

Pricilia Apriana
Program Studi Teknik Komputer,
Fakultas Teknik Elektro
Universitas Telkom
Bandung, Indonesia
priciliaapriana01@gmail.com

Atha Aulia Shidiq
Program Studi Teknik Komputer,
Fakultas Teknik Elektro
Universitas Telkom
Bandung, Indonesia
athaauliaashidiq.aas@gmail.com

Angel Metanosa Afinda
Program Studi Teknik Komputer,
Fakultas Teknik Elektro
Universitas Telkom
Bandung, Indonesia
angelmetanosa@gmail.com

Abstrak—Pertumbuhan volume data layanan publik di kota besar menuntut pendekatan big data yang mampu mengubah data mentah menjadi insight yang dapat ditindaklanjuti. Penelitian ini membangun dan membandingkan dua arsitektur pipeline data, yaitu Extract-Transform-Load (ETL) dan Extract-Load-Transform (ELT), untuk menganalisis pola keluhan warga terkait transportasi dan mobilitas perkotaan di New York City. Data diekstraksi dari dua sumber berbeda, yaitu NYC 311 Service Requests dan data cuaca historis Open-Meteo, untuk periode 2023 hingga 2024. Pada jalur ETL, data ditransformasi melalui tahap pembersihan, standarisasi, pengayaan fitur, dan validasi kualitas sebelum dimuat ke data warehouse PostgreSQL dengan skema bintang, sedangkan jalur ELT memuat data mentah terlebih dahulu sebelum ditransformasi di dalam warehouse menggunakan SQL. Hasil transformasi divisualisasikan dalam dashboard interaktif menggunakan Power BI. Analisis terhadap sekitar 500 ribu rekaman menunjukkan bahwa keluhan parkir liar mendominasi laporan, Brooklyn dan Queens menjadi wilayah dengan laporan terbanyak, serta volume laporan memuncak pada jam sibuk pagi hari dan hari kerja. Perbandingan kedua arsitektur memperlihatkan perbedaan karakteristik pada lokasi transformasi, kompleksitas, fleksibilitas, dan kemudahan pemeliharaan. Penelitian ini menyimpulkan bahwa integrasi data layanan publik dan data cuaca melalui pipeline yang terstruktur mampu menghasilkan insight yang relevan untuk mendukung pengelolaan mobilitas perkotaan.

Kata kunci: big data, ETL, ELT, layanan 311, analitik transportasi, data warehouse, skema bintang, Power BI

I. PENDAHULUAN

New York City sebagai salah satu kota terpadat di dunia menghasilkan volume data layanan publik yang sangat besar setiap harinya. Salah satu kanal utama interaksi warga dengan pemerintah kota adalah layanan 311, yaitu nomor non-darurat yang digunakan warga untuk melaporkan beragam permasalahan, mulai dari kondisi jalan, lampu lalu lintas, hingga parkir liar. Data yang terkumpul dari layanan ini berjumlah jutaan rekaman dan menjadi sumber yang berharga untuk memahami pola permasalahan transportasi dan mobilitas perkotaan.

Permasalahan mobilitas perkotaan tidak berdiri sendiri, melainkan dipengaruhi oleh berbagai faktor lingkungan, salah satunya kondisi cuaca. Hujan, angin kencang, dan suhu ekstrem dapat memperparah kerusakan infrastruktur sekaligus memengaruhi intensitas laporan warga. Namun,

data keluhan layanan publik dan data cuaca umumnya tersimpan secara terpisah, sehingga diperlukan suatu proses integrasi data yang terstruktur agar keduanya dapat dianalisis secara bersamaan.

Penelitian ini bertujuan membangun dua arsitektur pipeline data, yaitu Extract-Transform-Load (ETL) dan Extract-Load-Transform (ELT), untuk mengintegrasikan data NYC 311 Service Requests [1] dengan data cuaca historis Open-Meteo [2]. Kedua pipeline kemudian dibandingkan dari sisi karakteristik teknis, dan hasil transformasinya divisualisasikan dalam bentuk dashboard interaktif. Lingkup analisis dibatasi pada sembilan kategori keluhan yang berkaitan dengan transportasi pada periode 2023 hingga 2024. Kontribusi utama penelitian ini adalah penyajian perbandingan praktis antara pendekatan ETL dan ELT pada studi kasus yang sama, beserta insight mobilitas perkotaan yang dihasilkannya.

II. METODOLOGI

A. Sumber Data

Penelitian ini menggunakan dua sumber data dengan format yang berbeda. Sumber pertama adalah NYC 311 Service Requests dari NYC Open Data yang diakses melalui SoQL API dalam format CSV. Data difilter pada sembilan kategori keluhan yang berkaitan dengan transportasi, yaitu Street Condition, Traffic Signal Condition, Street Light Condition, Blocked Driveway, Illegal Parking, Highway Condition, Sidewalk Condition, Curb Condition, dan Bus Stop Shelter Complaint.


Sumber kedua adalah data cuaca historis dari Open-Meteo Historical Weather API dalam format JSON, dengan resolusi per jam untuk lokasi NYC pada koordinat 40,7128°LU dan -74,0060°BB. Variabel cuaca yang diambil mencakup suhu, kelembapan, presipitasi, hujan, salju, kode cuaca, dan kecepatan angin. Kedua sumber dibatasi pada periode yang sama, yaitu 1 Januari 2023 hingga 31 Desember 2024, agar dapat digabungkan berdasarkan waktu.

B. Arsitektur Sistem

Arsitektur sistem secara keseluruhan ditunjukkan pada Gambar 1. Data mentah hasil ekstraksi dari kedua sumber disimpan terlebih dahulu di Google Drive, kemudian diproses melalui dua jalur pipeline yang berjalan paralel. Kedua jalur

sama-sama menggunakan PostgreSQL yang di-host pada layanan serverless Neon sebagai data warehouse, serta Power BI sebagai alat visualisasi. Perbedaan mendasar di antara

keduanya terletak pada lokasi dan urutan proses transformasi data.



Gambar 1. Arsitektur pipeline data ETL dan ELT (NYC 311 & Weather).

C. Pipeline ETL

Pada pipeline ETL, transformasi dilakukan sepenuhnya di lingkungan Python (pandas) pada Google Colab sebelum data dimuat ke warehouse. Tahap Extract diimplementasikan melalui dua fungsi, yaitu `extract_etl_source1()` untuk membaca data NYC 311 dan `extract_etl_source2()` untuk membaca serta meratakan (flatten) data cuaca, dengan pencatatan log yang meliputi nama sumber, dimensi data, ukuran, dan waktu eksekusi.

Tahap Transform terdiri atas empat sub-tahap. Pertama, data cleaning yang mencakup penghapusan duplikat berdasarkan business key, penanganan missing value sesuai tipe data, standardisasi format tanggal, dan deteksi outlier dengan metode Interquartile Range (IQR). Kedua, standardisasi yang meliputi penyeragaman nama kolom ke format snake_case, normalisasi Min-Max pada kolom numerik, label encoding pada kolom kategorikal, dan penyelarasan tipe data. Ketiga, enrichment dan feature engineering yang menggabungkan data 311 dan cuaca berdasarkan jam serta menghasilkan sembilan fitur baru, antara lain `hour_of_day`, `is_weekend`, `is_rush_hour`, `response_time_hours`, `weather_risk_score`, dan `temp_category`. Keempat, validasi kualitas data dengan enam aturan, yaitu uniqueness, null, range, datatype consistency, referential integrity, dan distribusi data.

Tahap Load mendesain skema bintang (star schema) yang terdiri atas satu tabel fakta (`fact_311_requests`) dan tiga tabel dimensi (`dim_time`, `dim_location`, `dim_complaint`) dengan primary key dan foreign key yang terdokumentasi eksplisit [3]. Data dimuat secara bertahap (chunking) ke Neon, lalu diverifikasi melalui delapan query SQL analitik.

D. Pipeline ELT

Berbeda dengan ETL, pipeline ELT memuat data mentah terlebih dahulu ke warehouse, baru kemudian melakukan transformasi di dalam database menggunakan SQL [4]. Pada tahap Load, data NYC 311 dimuat sebagai teks murni ke tabel `elt_raw_311` menggunakan mekanisme COPY yang efisien,

sedangkan keseluruhan berkas JSON cuaca dimuat sebagai satu baris utuh ke tabel `elt_raw_weather`.

Tahap Transform dieksekusi sepenuhnya di Neon melalui serangkaian VIEW berlapis. Data cuaca dibongkar dari JSON menjadi bentuk tabular dengan fungsi `json_array_elements_text`, lalu dibersihkan dan dinormalisasi. Data 311 dibersihkan, dideduplikasi, dan dinormalisasi, dengan encoding kategorikal menggunakan fungsi `DENSE_RANK()`. Kedua sumber kemudian digabungkan pada VIEW akhir `elt_fact_311_analytics` yang memuat fitur-fitur turunan yang setara dengan jalur ETL. Validasi kualitas data juga dilakukan melalui enam aturan berbasis query SQL. Keluaran akhir berupa satu tabel datar (flat) yang langsung dikonsumsi oleh Power BI.

E. Visualisasi

Hasil dari kedua pipeline dihubungkan ke Power BI sebagai semantic model langsung dari Neon. Pada masing-masing dashboard didefinisikan empat ukuran (measure) DAX utama, yaitu Total Requests, Avg Response Time, Avg Weather Risk, dan % Rush Hour Bad Weather, yang ditampilkan sebagai kartu KPI dan dilengkapi beragam visual eksploratif [5].

III. HASIL DAN PEMBAHASAN

Hasil eksekusi kedua pipeline disajikan dalam bentuk dashboard interaktif. Secara umum, kedua dashboard menghasilkan pola dan angka yang konsisten, dengan perbedaan kecil yang bersumber dari strategi pengambilan sampel masing-masing pipeline.

A. Dashboard ETL


Dashboard ETL (Gambar 2) menampilkan total 500 ribu laporan, rata-rata waktu respons 60,7 jam, rata-rata weather risk 0,45, dan 13,99% laporan terjadi pada jam sibuk dengan cuaca buruk. Berdasarkan verifikasi delapan query SQL, Brooklyn menjadi wilayah dengan laporan terbanyak (181.708 atau 36,3%), diikuti Queens (161.807), Bronx (74.545), Manhattan (62.657), dan Staten Island (18.466). Jenis keluhan didominasi Illegal Parking dengan 295.591

laporan (59,1%), jauh melampaui Blocked Driveway (100.563) dan Street Condition (41.095). Distribusi per jam memperlihatkan puncak laporan pada pukul 09.00 (31.239 laporan), sementara perbandingan hari menunjukkan dominasi hari kerja sebesar 376.328 laporan (75,3%) dibanding akhir pekan 123.672 laporan (24,7%).


B. Dashboard ELT

Dashboard ELT (Gambar 3) menampilkan total 493.923 laporan, rata-rata waktu respons 61,19 jam, rata-rata weather

risk 0,46, dan 15,60% laporan pada jam sibuk dengan cuaca buruk. Pola yang dihasilkan konsisten dengan jalur ETL: Illegal Parking tetap mendominasi dengan 290.267 laporan, diikuti Blocked Driveway (98.505) dan Street Condition (42.541). Dashboard ini melengkapi analisis dengan peta sebaran borough serta heatmap yang memetakan jenis keluhan terhadap kategori suhu (cold, normal, hot), di mana mayoritas laporan terjadi pada kategori suhu normal (280.680) dan hot (180.103). Proporsi hari kerja dan akhir pekan pun serupa, yaitu 75,38% berbanding 24,62%.



Gambar 2. Dashboard ETL (star schema) pada Power BI.



Gambar 3. Dashboard ELT (flat view) pada Power BI.

TABEL I. Perbandingan Karakteristik Pipeline ETL dan ELT

Aspek	ETL (Pricilia)	ELT (Atha)
Urutan proses	Extract → Transform → Load	Extract → Load → Transform
Lokasi transformasi	Python (pandas) di Google Colab	Dalam database (SQL) di Neon
Bentuk data dimuat	Data sudah bersih dan terstruktur	Data mentah (string / JSON utuh)
Skema warehouse	Star schema: 1 fakta + 3 dimensi	Flat view: elt_fact_311_analytics
Encoding kategorikal	LabelEncoder (scikit-learn)	DENSE_RANK() (SQL)
Normalisasi	MinMaxScaler	Window function MIN/MAX
Total record	≈ 500.000	≈ 493.923
Kelebihan utama	Data konsisten dan terstruktur sebelum dimuat	Fleksibel, data mentah tersimpan, transformasi cepat di server

C. Perbandingan ETL dan ELT

Tabel I merangkum perbedaan karakteristik kedua pipeline. Perbedaan paling mendasar terletak pada lokasi transformasi: ETL memproses data di Python sebelum memuatnya, sedangkan ELT memuat data mentah lalu mentransformasinya di dalam database menggunakan SQL. Konsekuensinya, ETL menghasilkan struktur yang rapi berupa skema bintang yang siap dianalisis, sementara ELT menyimpan data mentah sehingga lebih fleksibel untuk transformasi ulang tanpa proses ekstraksi berulang.

Selisih jumlah record antara kedua pipeline (sekitar 500.000 pada ETL dan 493.923 pada ELT) bersifat wajar dan tidak menunjukkan inkonsistensi. Perbedaan tersebut bersumber dari strategi sampling: ETL mengambil sampel acak dari keseluruhan populasi hasil transformasi, sedangkan ELT memuat sejumlah baris pertama dari berkas mentah. Kesamaan pola pada kedua dashboard justru memperkuat keyakinan bahwa logika transformasi pada kedua jalur telah diterapkan secara setara.

Secara umum, pendekatan ETL unggul ketika konsistensi dan kerapian struktur data menjadi prioritas, sedangkan ELT unggul ketika dibutuhkan fleksibilitas dan pemanfaatan kemampuan komputasi server basis data. Pemilihan di antara keduanya bergantung pada kebutuhan organisasi, volume data, dan sumber daya yang tersedia [4], [6].

IV. KESIMPULAN

Penelitian ini berhasil membangun dan membandingkan dua arsitektur pipeline data, ETL dan ELT, untuk mengintegrasikan data NYC 311 dengan data cuaca Open-Meteo. Kedua pipeline mampu menghasilkan data warehouse yang tervalidasi serta dashboard yang menyajikan insight konsisten, antara lain dominasi keluhan parkir liar, konsentrasi laporan di Brooklyn dan Queens, serta puncak laporan pada jam sibuk dan hari kerja. Perbandingan menunjukkan bahwa ETL menawarkan struktur data yang lebih rapi, sedangkan ELT menawarkan fleksibilitas dan pemrosesan yang memanfaatkan basis data [7]. Penelitian selanjutnya dapat diarahkan pada pemrosesan keseluruhan populasi data, integrasi secara near real-time, serta penerapan model prediktif untuk mengantisipasi lonjakan keluhan berdasarkan kondisi cuaca.

DAFTAR PUSTAKA

- [1] NYC Open Data, “311 Service Requests from 2010 to Present,” City of New York. [Daring]. Tersedia: <https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2010-to-Present/erm2-nwe9>
- [2] Open-Meteo, “Historical Weather API,” Open-Meteo.com. [Daring]. Tersedia: <https://open-meteo.com/en/docs/historical-weather-api>
- [3] R. Kimball and M. Ross, The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling, 3rd ed. Indianapolis, IN: Wiley, 2013.
- [4] P. Vassiliadis, “A survey of Extract–Transform–Load technology,” International Journal of Data Warehousing and Mining, vol. 5, no. 3, pp. 1–27, 2009.
- [5] Microsoft, “What is Power BI?” Microsoft Learn. [Daring]. Tersedia: <https://learn.microsoft.com/power-bi/fundamentals/power-bi-overview>
- [6] The PostgreSQL Global Development Group, PostgreSQL 17 Documentation, 2024. [Daring]. Tersedia: <https://www.postgresql.org/docs/>
- [7] T. H. Davenport and J. G. Harris, Competing on Analytics: The New Science of Winning. Boston, MA: Harvard Business School Press, 2007.